

Rapport de projet ML

BirdClef+ 2026

Master MIND

MNEMOI Lina
PUTRI Dwi Prima Handayani

Année universitaire 2025-2026

Table des matières

1 Introduction **4**
1.1 Contexte et objectif 4
1.2 Hypothèses 4

2 Analyse des données **4**
2.1 Statistiques générales 4
2.2 Prétraitement et extraction de features pour l'analyse de données 5
2.2.1 Chargement et normalisation des fichiers audio 5
2.2.2 Extraction de features 5
2.3 Réduction de dimension et recherche de features discriminants 6

3 Méthode proposée **9**
3.1 Prétraitement 9
3.2 Modèles 9
3.2.1 Régression logistique 9
3.2.2 RandomForest 9
3.2.3 Gradient Boosting Stochastique 9

4 Résultats **10**
4.1 Vue d'ensemble des performances 10
4.2 Analyse par modèle 10
4.2.1 Régression Logistique 10
4.2.2 Random Forest 10
4.2.3 Gradient Boosting Stochastique 10
4.3 Discussion 11

5 Conclusion **11**

Abstract

Ce rapport présente notre participation au challenge BirdClef+ 2026, dont l'objectif est d'identifier automatiquement des espèces fauniques à partir d'enregistrements audio passifs collectés dans le Pantanal brésilien. Nous développons un pipeline de classification multi-label reposant sur l'extraction de 36 features acoustiques (MFCC, descripteurs spectraux, énergie RMS, taux de passage par zéro) à partir de fenêtres de 5 secondes. Une analyse exploratoire préalable révèle un dataset fortement déséquilibré, avec une distribution à longue queue et une absence de séparation géométrique des espèces dans l'espace des features. Trois modèles One-vs-Rest sont évalués : régression logistique, Random Forest et Gradient Boosting stochastique. Le Random Forest obtient les meilleures performances avec un F1 micro de 0,419 au seuil optimal de 0,3, mais un F1 macro de 0,022 révèle que les espèces rares restent quasiment non détectées. Ces résultats confirment que les features acoustiques classiques ne suffisent pas à la classification fine à l'échelle espèce et motivent le recours à des modèles pré-entraînés.

1 Introduction

1.1 Contexte et objectif

Ce rapport présente notre travail sur le challenge BirdClef+ 2026 dans le contexte de l'UE Machine Learning du Master MIND. Les données proviennent de plus de mille enregistreurs acoustiques déployés dans la région du Pantanal brésilien. Ces audios capturent des chants, des bruits et comportements des oiseaux et autres animaux dans la région. Leur analyse est essentielle pour surveiller la biodiversité et comprendre les dynamiques du changement climatique et des comportements de la faune selon les saisons. Cependant, le volume d'audio généré est trop considérable pour être examiné manuellement. Ainsi, notre objectif est de développer des modèles d'apprentissage machine capables d'identifier les espèces présentes dans la région.
Notre problématique se formule ainsi : Comment traiter les audios et entraîner un modèle d'apprentissage machine pour la détection audio d'espèces à partir de sons bruts provenant du Pantanal ?

1.2 Hypothèses

Pour répondre au problème, nous formulons plusieurs hypothèses :

- Les caractéristiques extraites des signaux audio, notamment les MFCC et RMS, contiennent suffisamment d'information discriminante pour distinguer les espèces.
- Des modèles ensemblistes robustes tels que le Random Forest et le Gradient Boosting sont capables de généraliser sur des données déséquilibrées et bruitées, sans nécessiter une architecture deep learning complexe.
- La faible représentation de certaines classes (reptiles, amphibiens) constituera un défi majeur pour la généralisation du modèle.

2 Analyse des données

2.1 Statistiques générales

Le fichier `taxonomy.csv` recense 234 espèces, chacune décrite par son nom scientifique, son nom commun et sa classe animale. Cinq classes sont représentées : Oiseaux (Aves), Amphibiens (Amphibia), Insectes (Insecta), Mammifères (Mammalia) et Reptiles (Reptilia).

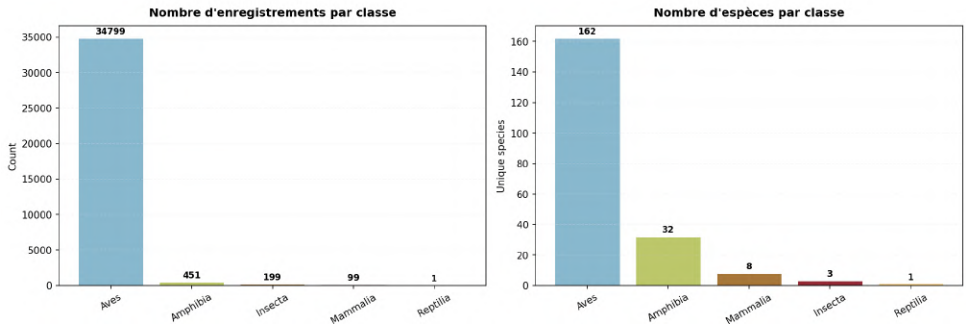


Figure 1: Nombre d'enregistrements et d'espèces par classe taxonomique

Les oiseaux (Aves) dominent largement le dataset, représentant à eux seuls environ 35 000 enregistrements sur les quelque 36 000 disponibles dans les audios d'entraînement d'espèce isolée (dossier `train_audio`). Les autres classes sont très minoritaires : 35 espèces d'amphibiens, 28 d'insectes, 8 de mammifères et un seul reptile. L'objectif majeur est néanmoins de distinguer les espèces d'oiseaux entre elles.
Un autre déséquilibre important concerne la couverture entre les données d'entraînement labellisées et les soundscapes. Les enregistrements de 28 des espèces ne figurent que dans les soundscapes. En effet, 206 espèces présentes uniquement dans `train_audio`, 28 uniquement dans les soundscapes, et 75 dans les deux. Les espèces manquantes dans le dossier `train_audio` proviennent principalement de la classe des insectes (25 espèces absentes) et des amphibiens (3 espèces absentes). Ces espèces ne pourront

pas être apprises directement par supervision classique, ce qui pose un problème de généralisation pour l'évaluation finale.
La distribution des enregistrements par espèce suit une loi à longue queue, comme on le voit sur la figure 2.

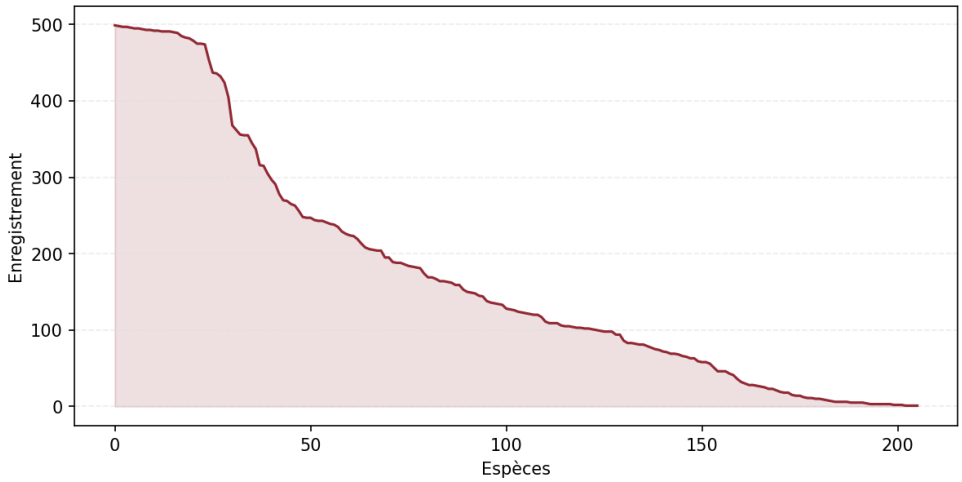


Figure 2: Distribution longue queue

Les espèces les mieux représentées atteignent jusqu'à 499 enregistrements, tandis qu'une fraction significative d'espèces en compte moins de dix. Cette asymétrie constitue un défi majeur pour l'entraînement : le modèle risque d'être biaisé vers les espèces dominantes au détriment des espèces rares. En outre, les espèces d'oiseaux présentent la distribution la plus large, avec un nombre d'enregistrements allant de très peu d'échantillons à 499, pour une médiane de 168 enregistrements par espèce. Les espèces d'insectes montrent une variabilité modérée, mais restent significativement moins représentées que les oiseaux. Les amphibiens et les mammifères disposent en général de très peu d'enregistrements : la majorité des espèces d'amphibiens compte moins de 30 enregistrements, tandis que les mammifères en ont entre 1 et 43. Une seule espèce de reptile est présente dans le jeu de données.

2.2 Prétraitement et extraction de features pour l'analyse de données

Pour l'analyse des données audio, nous extrayons des features de chaque audio après avoir appliqué une normalisation sur les fichiers audio.

2.2.1 Chargement et normalisation des fichiers audio

Tous les fichiers audio sont chargés via la bibliothèque `librosa` avec les paramètres suivants : fréquence d'échantillonnage `sr=32 000 Hz` et conversion en signal mono (`mono=True`). Par ailleurs, les fichiers audio du dossier `train_soundscapes` sont découpés en fenêtres de 5 secondes pour correspondre aux annotations du fichier `train_soundscapes_labels.csv`.

2.2.2 Extraction de features

Pour chaque fichier audio, 36 features sont extraits. Ces features permettent de résumer le timbre, la fréquence et la dimension énergétique du signal. Ce choix s'appuie sur des travaux antérieurs en classification bioacoustique [1, 4, 2]. Le tableau 1 synthétise les features extraits et la raison du choix.

Table 1: Features extraits par fenêtre de 5 secondes et leur interprétation acoustique.

Feature	**Statistiques**	**Justification**
RMS Energy	mean, std	Énergie globale du signal ; pour distinguer les sons forts (souvent oiseaux chanteurs) des sons discrets (insectes, amphibiens nocturnes). [1].
Zero Crossing Rate	mean, std	Taux de passages par zéro ; pour distinguer les signaux percussifs des signaux tonaux. [1].
Spectral Centroid	mean, std	Proxy de la "hauteur perçue" du son. Les mammifères vocalisent typiquement plus bas que les oiseaux. [1].
Spectral Bandwidth	mean, std	Étalement du spectre autour du centroïde ; étroit pour les sons purs et large pour les sons complexes. [1].
Spectral Rolloff	mean, std	Fréquence en dessous de laquelle se concentre 85 % de l'énergie ; discrimine les espèces à vocalisation aiguë des espèces graves. [1].
MFCC 1-13	mean, std	encondage de la forme globale du spectre (timbre). [1, 4, 2]

2.3 Réduction de dimension et recherche de features discriminants

Nous voulons évaluer la séparabilité des classes et des espèces d'oiseaux dans l'espace des features extraits. Pour cela, nous appliquons deux méthodes de réduction de dimension : une ACP suivie d'un t-SNE. Ni la PCA ni la t-SNE ne montrent de distinction forte entre les classes. Les méthodes montrent seulement que les espèces d'oiseaux sont beaucoup plus présentes, et les autres classes ne se distinguent pas dans d'autres clusters (Figue 3).

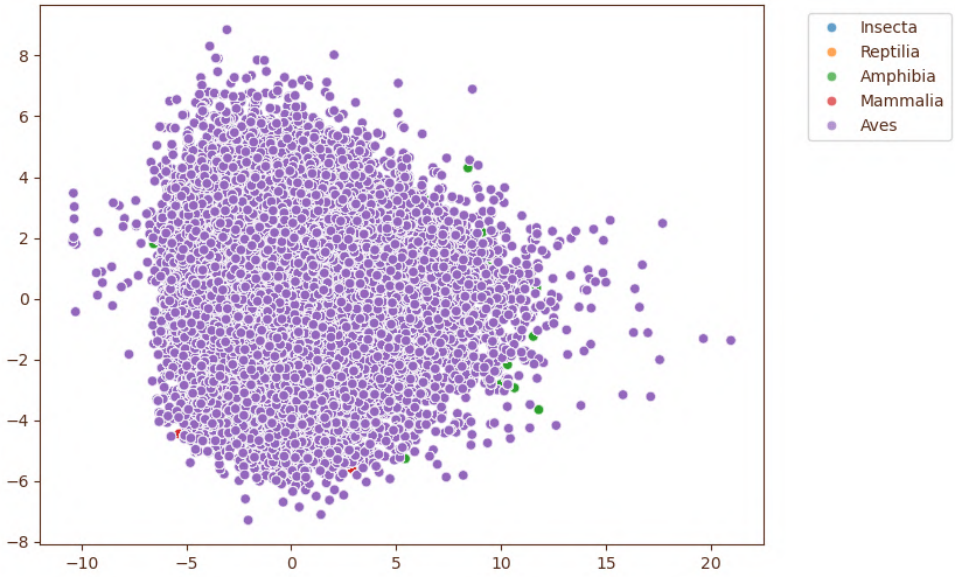


Figure 3: ACP : aucun cluster par classe n'est observable.

La figure 4 présente la projection t-SNE sur les 20 espèces d'oiseaux les plus représentées.

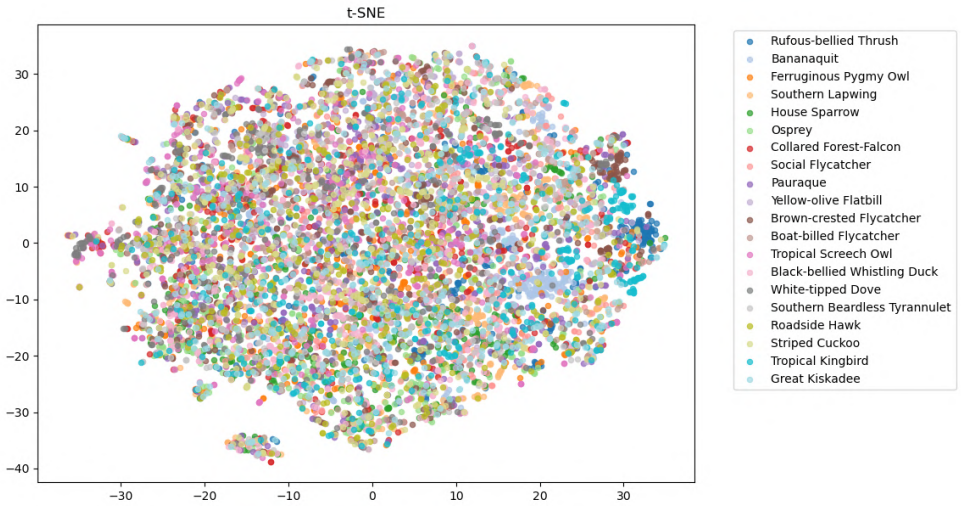


Figure 4: Projection t-SNE sur les 20 espèces les plus représentées : aucun cluster par espèce observable.

Les points correspondant aux différentes espèces se mélangent uniformément dans l'espace projeté, sans former de clusters identifiables. Ainsi, les features extraits ne permettent pas de séparation géométrique simple des espèces d'oiseaux, ni des classes entre elles. Des frontières de décision non linéaires complexes seront donc utiles.
Pour compléter cette analyse, la figure 5 examine les signatures acoustiques des 20 espèces d'oiseaux les plus présentes dans les audios d'entraînement à travers deux descripteurs spectraux : le centroïde spectral et le rolloff.

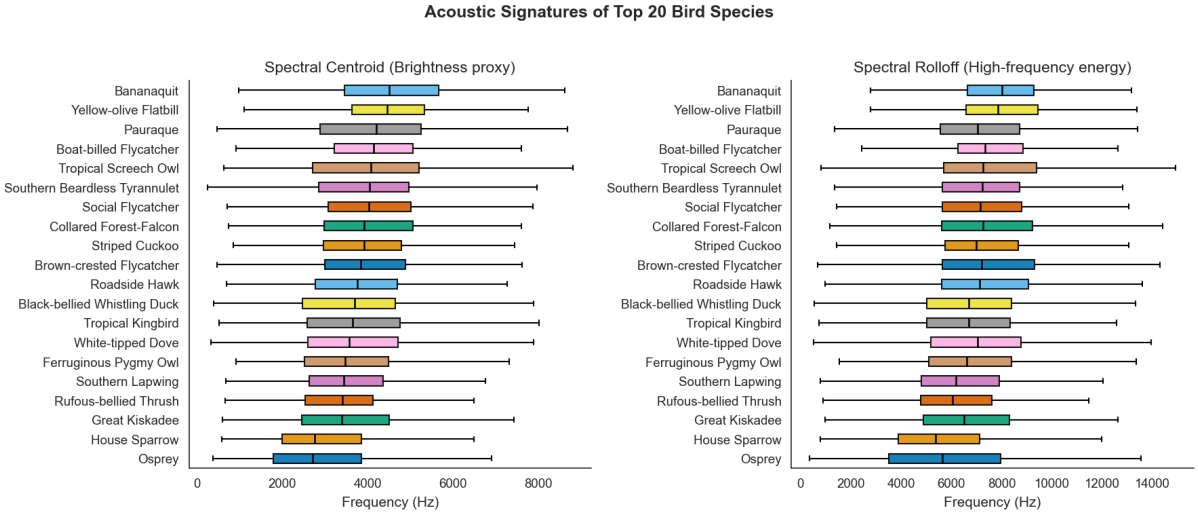


Figure 5: Centroïde spectral et rolloff des 20 espèces les plus représentées.

Même parmi les espèces les mieux représentées, les distributions se chevauchent largement. En effet, la majorité des espèces présente un centroïde compris entre 2 500 et 4 000 Hz, avec des étendues similaires. Quelques espèces se distinguent toutefois quelque peu : l'Osprey et le House Sparrow occupent les fréquences les plus basses, tandis que le Bananaquit se situe le plus haut. Ces différences restent insuffisantes pour une classification fiable, ce qui confirme les conclusions du t-SNE : des features complémentaires et des modèles non linéaires sont nécessaires.
Une analyse au niveau des classes taxonomiques révèle des différences spectrales exploitables. La figure 6 montre que les classes se distinguent partiellement par leur hauteur spectrale.

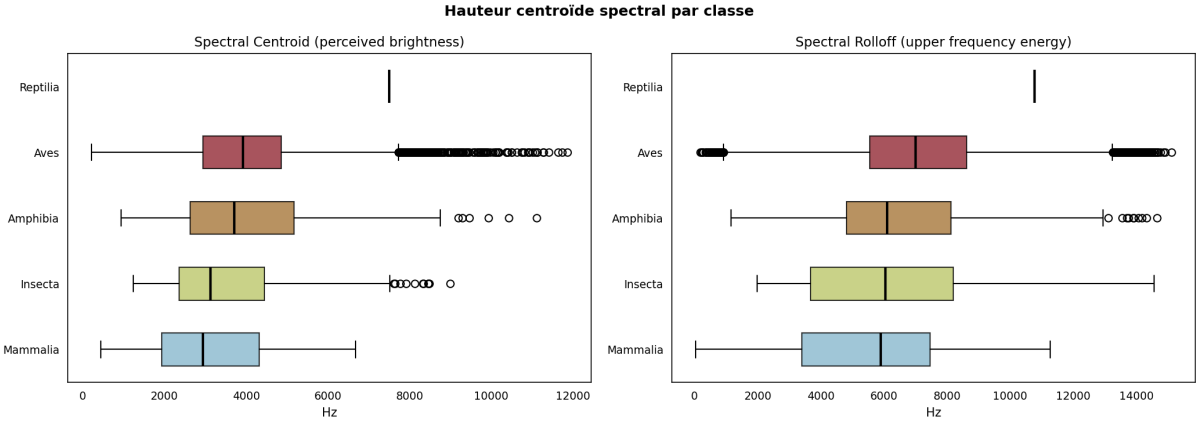


Figure 6: Centroïde spectral et rolloff par classe taxonomique.

Les mammifères produisent des sons concentrés dans les basses fréquences (centroïde médian autour de 2 500 Hz), tandis que les insectes et les oiseaux occupent des plages plus élevées. Les reptiles, représentés par un seul individu, apparaissent comme un point isolé à haute fréquence.
Les coefficients MFCC normalisés confirment l'existence de signatures timbrales distinctes par classe (figure 7).

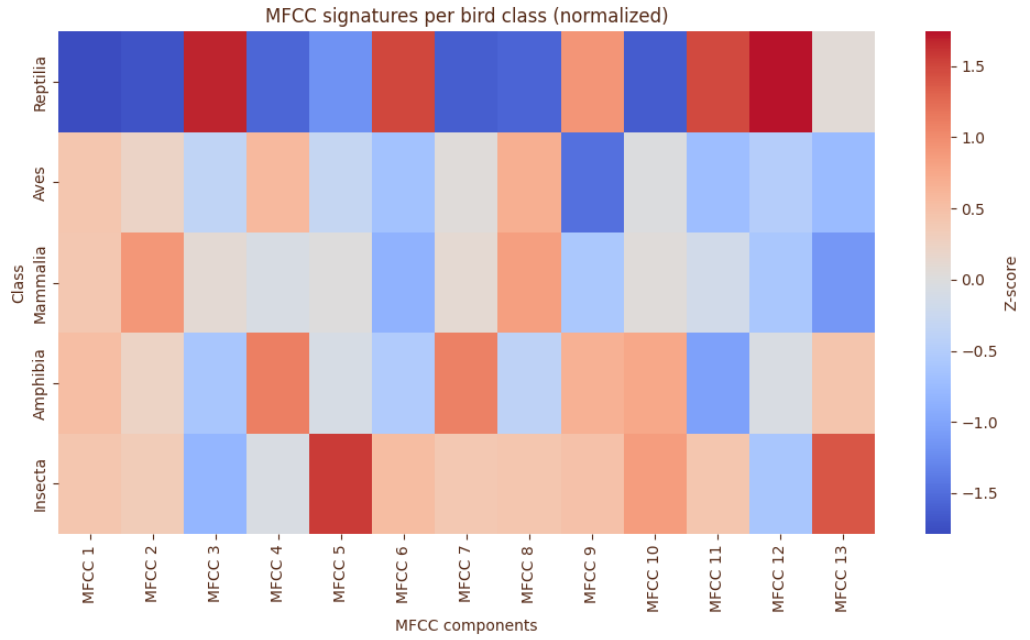


Figure 7: Signatures MFCC moyennes par classe (Z-scores normalisés sur 13 coefficients).

En excluant la classe reptile qui nest pas assez représentée, nous remarquons que les quatre classes ont des signatures timbrales très similaires. La classe insecte se distingue quelque peu des autres, tout comme le MFCC2 pour la classe mammifère.

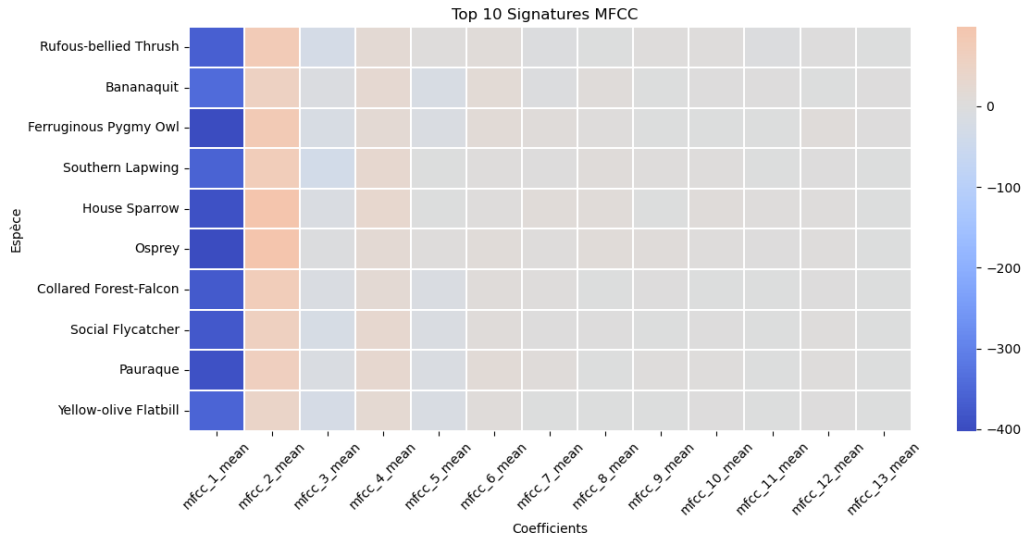


Figure 8: Signatures MFCC moyennes pour les 10 espèces les plus représentées.

Au niveau espèce, pour les 10 espèces d'oiseau les plus représentées : les lignes pour chaque espèce d'oiseau sont quasiment toutes identiques figure 8.
Ainsi, l'analyse des données révèle plusieurs challenges : il existe des features discriminants entre les classes. Mais aucune feature prise individuellement ne semble permettre une séparation claire des espèces d'oiseaux. Des modèles ensemblistes pourraient permettre d'obtenir des résultats corrects pour la tâche de multiclassification.

3 Méthode proposée

3.1 Prétraitement

La tâche de classification est multilabel. Ainsi, nous binarisons la colonne `primary_label` de nos données en un vecteur représentant les 234 espèces. Nous divisons ensuite le jeu de données en un ensemble d'entraînement et de validation. L'ensemble d'entraînement est constitué de 100% des audios des espèces isolés et de 80% des audios soundscapes. Ainsi, pour la validation, nous utilisons les 20% d'exemples restants des audios soundscapes. Nous nous assurons que l'ensemble des fenêtres d'un même audio est contenu dans le même ensemble.

3.2 Modèles

3.2.1 Régression logistique

La régression logistique One-vs-Rest constitue la baseline du projet de par son coût computationnel faible et sa simplicité. Pour un problème à K classes, nous entraînons K classifieurs binaires indépendants qui distinguent chaque espèce de toutes les autres. Les classes sont pondérées proportionnellement à leur fréquence pour compenser le déséquilibre du dataset.

3.2.2 RandomForest

Le Random Forest est un modèle ensembliste basé sur l'agrégation de plusieurs arbres de décision entraînés sur des sous-ensembles aléatoires des données et des features. Il présente plusieurs atouts dans notre contexte : robustesse au bruit et aux valeurs aberrantes, bonne gestion des déséquilibres de classes via le paramètre `class_weight`, et faible risque de surapprentissage grâce à l'agrégation. Il constitue une baseline solide et interprétable avant d'envisager des approches plus complexes.

3.2.3 Gradient Boosting Stochastique

Le Gradient Boosting Stochastique est une méthode ensembliste qui construit séquentiellement des arbres faibles, chacun corrigeant les erreurs du précédent. Par rapport au Random Forest, il offre générale-

ment de meilleures performances prédictives sur des données structurées déséquilibrées. Cependant, l'entraînement est plus long et il est plus sensible aux hyperparamètres.

4 Résultats

4.1 Vue d'ensemble des performances

Le tableau 2 synthétise les performances des trois modèles évalués à leur seuil par défaut de 0,5 (une prédiction est considérée bonne si la probabilité de la classe est supérieure à 0,5. Il y a 234 classes pour 234 espèces). Les espèces sans exemple en validation ne peuvent pas être évaluées par ROC-AUC et sont donc sautées. Ainsi, 42 labels sur 75 ont été utilisés pour calculer la métrique ROC-AUC Macro.

Table 2: Comparaison des modèles à threshold = 0,5.

Modèle	ROC-AUC macro	F1 micro	F1 macro	Précision micro	Rappel micro
Régression logistique	**0.7337**	0.1313	0.0479	0.0487	**0.6246**
Random Forest	0.6801	**0.3364**	0.0217	**0.9113**	0.2063
Gradient Boosting	0.5973	0.2961	**0.0319**	0.3098	0.2836

Table 3: Analyse des seuils de décision : F1 micro par modèle.

Modèle	Seuil 0.3	Seuil 0.5	Seuil 0.7	Seuil 0.9
Régression logistique	0.090	0.131	0.199	**0.334**
Random Forest	**0.419**	0.336	0.274	0.141
Gradient Boosting	0.298	0.296	0.280	0.220

4.2 Analyse par modèle

4.2.1 Régression Logistique

La régression logistique One-vs-Rest constitue la baseline du projet. Elle obtient le meilleur ROC-AUC macro (0,834), ce qui indique une bonne capacité à ordonner les espèces présentes avant les absentes à seuil fixe de 0,5. Cependant, ce score est trompeur : la précision micro chute à 0,049 pour un rappel de 0,625. Le modèle prédit donc massivement la présence de toutes les espèces. L'analyse des seuils montre qu'à 0,9, le F1 micro remonte à 0,334.
Ce comportement est caractéristique d'un modèle linéaire qui maximise le rappel au détriment de la précision globale, même avec `class_weight="balanced"`.

4.2.2 Random Forest

Le Random Forest est le modèle le plus performant en termes de F1. À seuil 0,5, il obtient un F1 micro de 0,336, avec une précision micro exceptionnellement élevée (0,911) : quand il prédit la présence d'une espèce, il a raison dans 91% des cas. En revanche, son rappel micro de 0,206 révèle qu'il manque la grande majorité des espèces présentes. Son comportement est inverse à celui de la régression logistique.
Le F1 macro de 0,022 est particulièrement faible, révélant que les performances sont très inégales entre espèces. Le modèle détecte bien les espèces fréquentes mais échoue presque totalement sur les espèces rares. Le seuil optimal est 0,3, où le F1 micro atteint 0,419, confirmant que les probabilités sont très sous-estimées.

4.2.3 Gradient Boosting Stochastique

Le Gradient Boosting occupe une position intermédiaire. Son ROC-AUC macro (0,597) est le plus faible des trois. En revanche, son comportement précision-rappel est le plus équilibré à seuil 0,5 : précision micro de 0,310 et rappel micro de 0,284, pour un F1 micro de 0,296. Il présente également la plus faible sensibilité au seuil de décision —:le F1 micro varie de 0,298 à 0,220 entre les seuils 0,3 et 0,9. Ses probabilités sont donc mieux calibréees que le Random Forest.

4.3 Discussion

Ces performances nous montrent que le ROC-AUC n'est pas une métrique fiable dans ce contexte. La régression logistique obtient le meilleur ROC-AUC (0,734) mais le pire F1 (0,131) au seuil 0,5. Cela s'explique par le fait que le ROC-AUC mesure la capacité de ranking sans tenir compte du seuil de décision contrairement au F1. Le Random Forest obtient les meilleurs résultats avec un F1 micro de 0,419 au seuil optimal de 0,3. Cependant, son F1 macro de 0,022 expose une limite critique : les performances sont concentrées sur les espèces dominantes (principalement les oiseaux bien représentés), tandis que les espèces rares sont quasiment ignorées. Le Gradient Boosting offre quant à lui les performances les plus stables et les probabilités les mieux calibrées, au prix d'un F1 micro légèrement inférieur.
Enfin, les performances globales restent très limitées et cohérentes avec les conclusions de l'analyse exploratoire. Les features numériques extraits ne permettent pas une séparation fine des 206 espèces. La grande majorité des espèces rares (amphibiens, mammifères, reptiles) sont probablement non détectées. Des approches basées sur des représentations temporelles plus riches comme les spectrogrammes seraient nécessaires pour progresser significativement sur ce problème.

5 Conclusion

Ce projet a porté sur la détection d'espèces fauniques à partir d'enregistrements audio passifs du Pantanal brésilien, dans le cadre du challenge BirdClef+ 2026. L'analyse exploratoire a mis en évidence un dataset fortement déséquilibré, avec une distribution à longue queue et une absence de séparation géométrique des espèces dans l'espace des features numériques.
Le pipeline développé repose sur 39 features acoustiques et trois modèles One-vs-Rest. Le Random Forest s'est révélé le plus performant (F1 micro = 0,419), mais le rappel reste faible (0,206) et le F1 macro proche de 0 (0,022). Cela révèle les limites d'une représentation scalaire qui efface la structure temporelle des vocalisations face à 234 espèces déséquilibrées.
Ces résultats ouvrent plusieurs perspectives d'amélioration. À court terme, on peut considérer l'intégration de features contextuelles non-audio comme les coordonnées géographiques ou la saison d'enregistrement. A long terme, le recours à des modèles pré-entraînés comme Perch qui opèrent directement sur des spectrogrammes peut être intéressant.

References

[1] Ghani, B., and Hallerberg, S. "A Randomized Bag-of-Birds Approach to Study Robustness of Automated Audio Based Bird Species Classification." *Applied Sciences*, vol. 11, no. 19, 2021, 9226. DOI: https://doi.org/10.3390/app11199226

[2] Qin, R., and Huang, J. "Towards Accurate Bird Sound Recognition Through Multi-Scale Texture-Aware Modeling." *npj Acoustics*, vol. 1, 2025, p. 22. DOI: https://doi.org/10.1038/s44384-025-00025-6

[3] Noumida, A., and Rajan, R. "Multi-Label Bird Species Classification from Audio Recordings Using Attention Framework." *Applied Acoustics*, vol. 197, 2022, p. 108901. DOI: https://doi.org/10.1016/j.apacoust.2022.108901

[4] Wu, C. S., Kosuru, S., and Tippareddy, S. "Bird Species Identification from Audio Data." In: *2023 IEEE Ninth International Conference on Big Data Computing Service and Applications (BigDataService)*, Athens, Greece, 2023, pp. 58-62. DOI: https://doi.org/10.1109/BigDataService58306.2023.00015